MSMIN5IN52 · GenAI · Sujet F1

QA E2E d’Open WebUI

Tester un parcours RAG et outils sur deux tenants isolés,
avec Playwright, Docker et un LLM simulé

Playwright | Open WebUI × 2 | Docker Compose | Mock LLM

@Will-emma & @StarkMac22

Soutenance · 28 octobre 2026

LE PROBLÈME

Comment tester une application de chat LLM de façon fiable ?

Un LLM ne répond jamais deux fois pareil

Un échec ne dit pas si la faute vient de l'app ou du modèle → **mock déterministe**

Le streaming rend les tests fragiles

Lire trop tôt donne un texte tronqué, donc des tests instables → **attente conditionnelle**

Le multi-tenant ne tolère aucune fuite

Personne ne doit voir les données d'un autre tenant ou utilisateur → **tests d'isolation**

MVP

10 tests E2E, fixtures isolées, traces et captures d'échec, exécution CI

Réussite

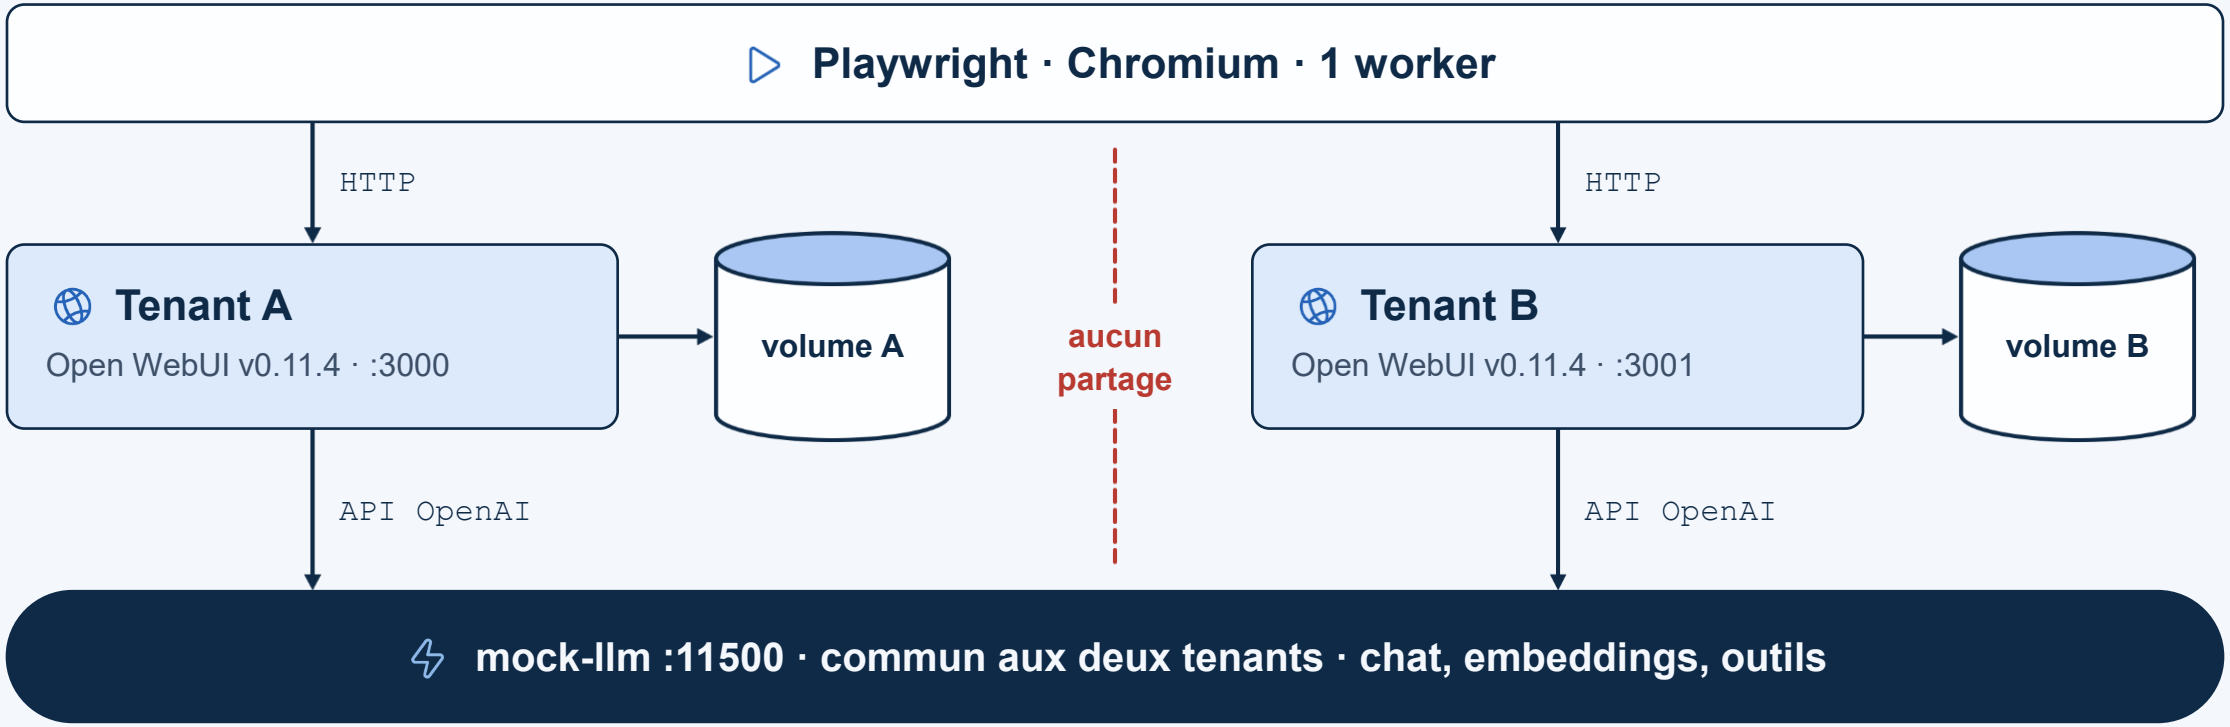
Nominal + erreur, aucune dépendance à l'ordre, rapport de flakiness sur 10 runs

Contraintes

Docker + navigateur, pas de GPU, budget < 5 €

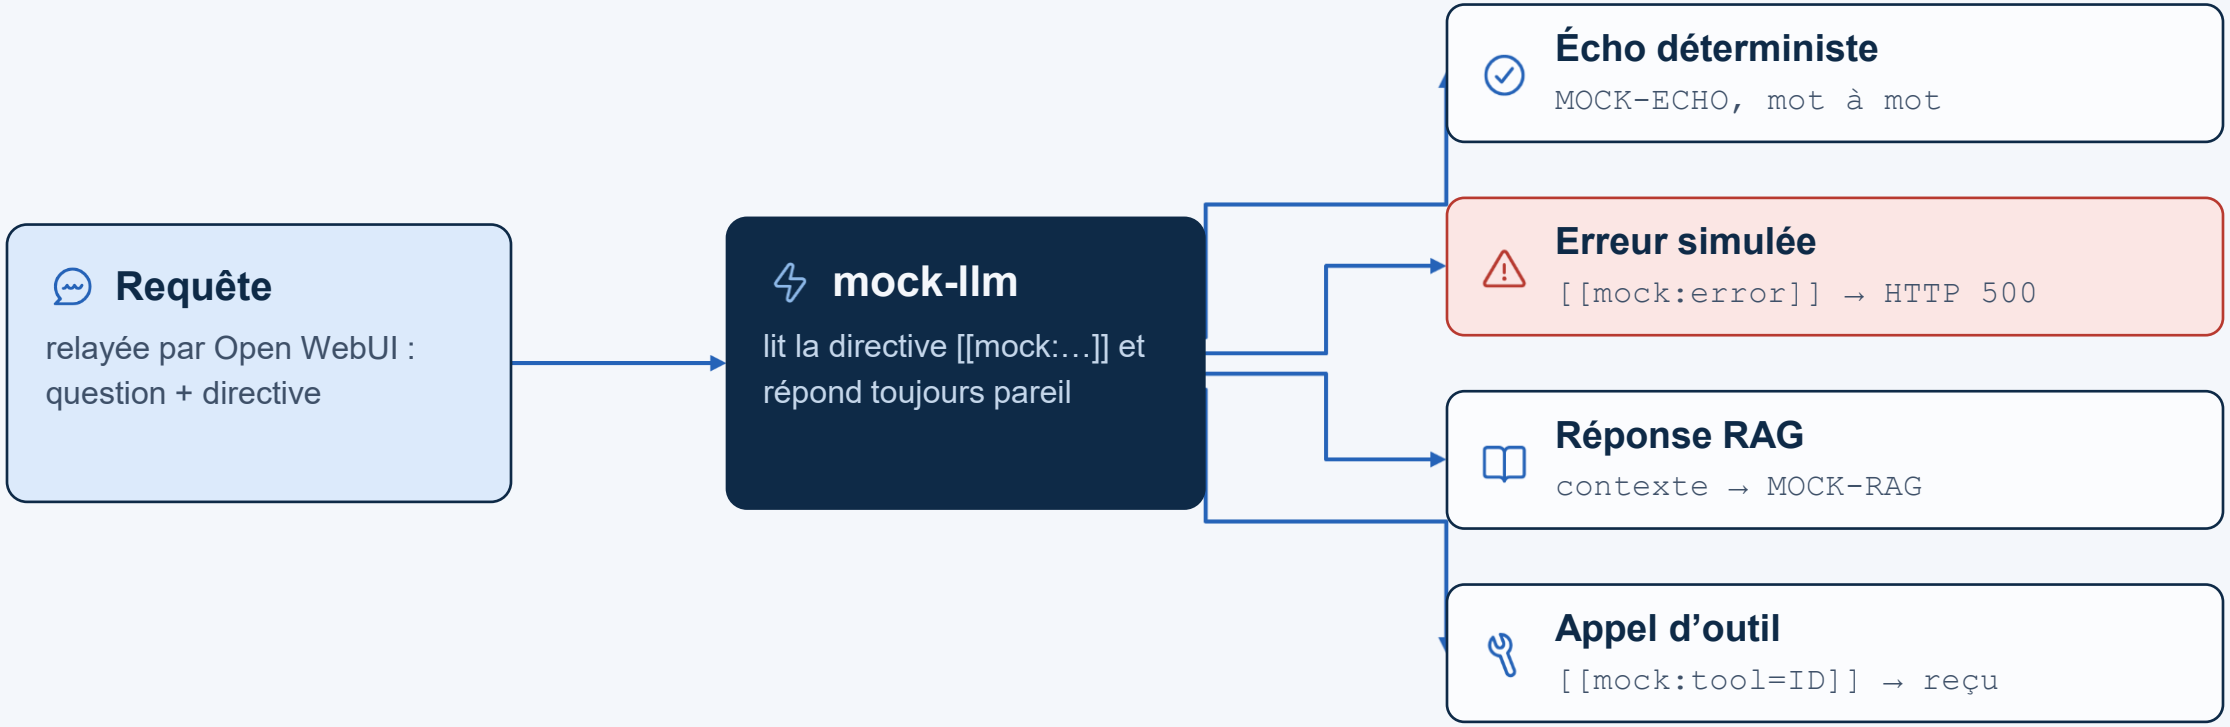
ARCHITECTURE

Deux tenants isolés, un mock LLM commun



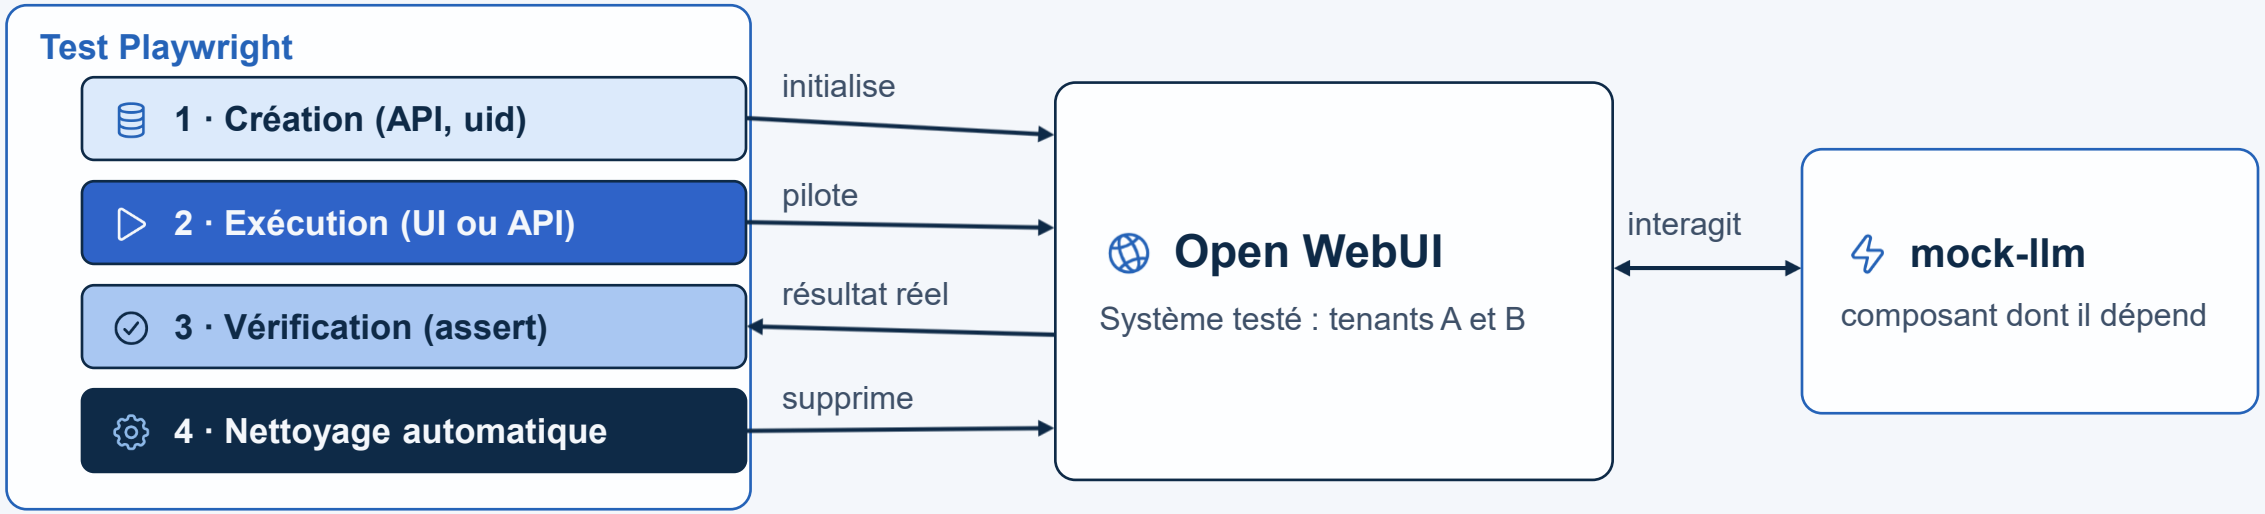
Docker Compose · **aucune clé API, aucun GPU** · simulation locale, pas de production

Un LLM simulé : même entrée, même réponse



Aussi : débit irrégulier [[mock:jitter=MS]] · latence · embeddings simulés (dim. 256)

Cycle de vie d’un test et de ses fixtures



Nettoyage automatique des ressources temporaires

utilisateurs · bases RAG · fichiers · outils

Supprimés dans des blocs finally, même si une assertion échoue. Limite : certaines conversations de test peuvent rester dans les volumes Docker.

COUVERTURE

16 scénarios répartis sur six parcours

Connexion — 3

Session reprise · mauvais mot de passe → erreur · connexion d'un utilisateur

Chat — 4

Streaming complet · débit irrégulier · persistance côté serveur · panne LLM

RAG — 3

Réponse fondée sur le document · base visible · source citée dans le chat

Isolation — 3

Jeton A refusé par B (401) · base A invisible depuis B · chat d'autrui illisible

Rôles — 2

API d'administration refusée à un utilisateur (401) · redirection hors de /admin

Outils — 1

Outil activé dans le chat réellement exécuté, reçu vérifié côté mock

16 scénarios fonctionnels + 1 setup d'authentification = **17 tests** dans npm test · erreurs couvertes : mot de passe, panne LLM, 401

COMMENT ON PROUVE

Vérifier le résultat réel, pas seulement l’affichage

Streaming

- Question + marqueur unique
- Réponse streamée mot à mot
- Marqueur final affiché
- **Réponse complète vérifiée**

RAG

- Document synthétique indexé
- Base jointe depuis le chat
- Contexte injecté → MOCK-RAG
- **Réponse + source citée**

Outil

- Outil activé dans le chat
- Appel réel de l’outil
- Reçu enregistré par le mock
- **Vérifié à part : 1 appel**

COMPARAISON À UNE BASELINE

Pourquoi une attente fixe échoue face au streaming

Attente fixe · baseline volontairement fragile

0/10 · échec attendu

Premiers caractères reçus → Pause fixe de 500 ms → Lecture unique : texte tronqué

Réponse au moment de la lecture — incomplète

Attente conditionnelle · assertion Playwright

10/10 · succès

Premiers caractères reçus → Assertion réessayée ≤ 30 s → Texte complet détecté

Réponse au moment de la lecture — complète

F1 — QA E2E d'Open WebUI · 8 · même scénario : ~25 mots streamés avec un délai aléatoire (jitter)

RÉSULTATS MESURÉS

Des résultats mesurés, pas supposés

160/160

exécutions réussies : 16 scénarios × 10 runs, sans retry



17/17

tests Playwright en 36 s (16 scénarios + 1 setup)

0

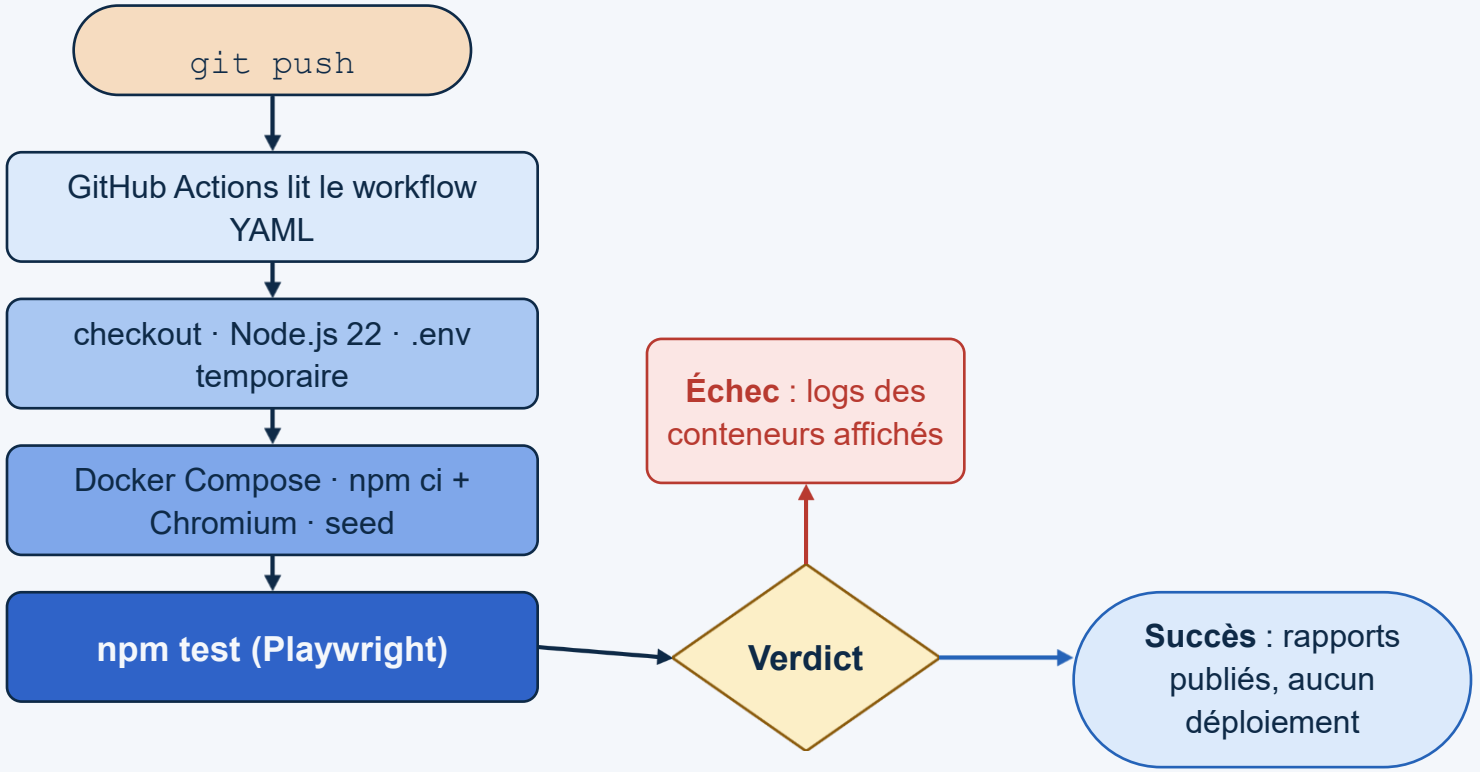
échec et 0 test ignoré dans la suite principale

44,2 s

par cycle complet en moyenne, baseline comprise

Campagne locale du 26/10/2026 · reports/flakiness.md · la baseline (0/10, attendu) n’est pas comptée dans les 160 · commit de base 3307360, arbre de travail modifié au lancement

CI GitHub Actions — 17/17 sur la version finale



Artifacts publiés

- Rapport HTML Playwright
- Traces (en cas d'échec)
- Captures (en cas d'échec)

Exécuté sur le fork, hors PR

`groupe-owui-qa/ci/e2e.yml`

run vert 17/17 le 27/10 · branche ci/groupe-owui-qa-final

BILAN

Ce qui est fait, face aux attendus du sujet

Attendu	Statut	Preuve
MVP · 10 tests E2E	Fait	16 scénarios fonctionnels (+ setup : 17/17)
MVP · fixtures isolées	Fait	5 fixtures, noms uniques, nettoyage en finally
MVP · traces et captures	Fait	conservées automatiquement en cas d’échec
MVP · exécution CI	Fait	run GitHub Actions vert : 17/17, version finale
Réussite · nominal et erreur	Fait	mauvais mot de passe, panne LLM, 401
Réussite · ordre indifférent	Conçu	données propres à chaque test, ordre non permuté
Réussite · flakiness 10 runs	Fait	160/160, baseline 0/10 comme prévu
Budget inférieur à 5 €	Fait	0 € de LLM grâce au mock local
Extensions	Non fait	accessibilité, charge, matrice de versions

Ce que la suite ne prouve pas encore

⚠ Limites connues

- Le mock teste l'intégration, pas la qualité d'un vrai modèle
- Deux instances locales : simulation, pas sécurité de production
- Sélecteurs liés à Open WebUI v0.11.4
- Un seul worker : pas de parallélisme
- Des conversations de test restent dans les volumes

Prochaines étapes

- Relancer la CI plusieurs fois pour mesurer sa stabilité
- Mesurer l'indépendance : ordre inversé, --repeat-each
- Accessibilité avec axe-core
- Charge légère et matrice de versions Open WebUI
- Un run optionnel avec un vrai modèle

ORGANISATION

Contributions

@Will-emma

Environnement Docker (deux tenants + mock LLM), structure du projet, premiers tests Playwright, fixtures et configuration de l’environnement de test.

@StarkMac22

Parcours RAG et outils dans le navigateur, fixtures et mock LLM améliorés, validation 17/17, campagne 160/160, documentation et rapports.

Assistance IA : Claude et Codex, utilisés pour corriger des bugs

Méthode : branches Git dédiées, commits distincts, vérification locale, intégration dans le fork puis Pull Request

DÉMONSTRATION

Une démo rejouable en quatre étapes

Préparé en amont : Node.js, dépendances (npm ci), Chromium et fichier .env

1 **Docker**
`npm run env:up`
2 tenants + mock

2 **Comptes**
`npm run seed`
admin sur A et B

3 **Playwright**
`npm test`
les 17 tests

4 **Rapport HTML**
`npm run report`
résultats et traces

Après la démo : nettoyage
npm run env:down · arrête sans effacer les volumes

Plan B
Rapports Playwright et flakiness déjà générés

EN RÉSUMÉ

Merci

16 scénarios E2E · 2 tenants isolés · 160/160 sur 10 runs · baseline naïve 0/10 · 0 € de LLM

@Will-emma & @StarkMac22 · groupe-owui-qa · Open WebUI v0.11.4 · Playwright · Docker